ESTUDO DE CASO · CIÊNCIA DE DADOS NO BRASILEIRÃO

SANTOS 0 – 0 ATLÉTICO-MG 16'

09/09/2020 · Vila Belmiro · goleiro do Atlético-MG expulso

QUANTO CUSTA UMA EXPULSÃO?

Minuto, placar e posição do cartão vermelho em 4.179 partidas da Série A (2014–2024), e o que a comissão técnica pode fazer com isso.

José Felix · Rafael Anacleto
Ciência de Dados · UFAL/IC · 2026.1

UM EM CADA CINCO JOGOS DO BRASILEIRÃO TEM EXPULSÃO

1.086
CARTÕES VERMELHOS EM 2014–2024

21,0%
DAS PARTIDAS TÊM PELO MENOS UM

4,9
VERMELHOS POR TIME, POR TEMPORADA

A PERGUNTA DA COMISSÃO TÉCNICA

“Levamos vermelho de novo. Quanto isso nos custou, e dava para evitar?”

Hoje, a resposta é decidida no improviso, à beira do campo.

VERMELHO NÃO É AZAR: TEM HORA, PLACAR E POSIÇÃO

HORA

18×

mais vermelhos no fim do que no início

PLACAR

+39%

de risco para quem está **perdendo**

POSIÇÃO

+16%

de vermelhos para **zagueiros**

PREVISÍVEL → DÁ PARA PREVENIR

Trocar o atleta certo **antes**.

CUSTO MEDIDO → DÁ PARA REAGIR

Plano pronto para jogar com 10.

UMA EXPULSÃO CUSTA 0,30 PONTO, E A CONTA VEM NA DEFESA

−0,30
PONTO POR EXPULSÃO

+53%
GOLS SOFRIDOS, COM UM A MENOS

−37%
GOLS MARCADOS, COM UM A MENOS

+39%
RISCO DE VERMELHO PERDENDO

684 expulsões comparadas a times no mesmo minuto, mando e placar · todos os números com IC 95%.

PREVENIR ANTES, REAGIR DEPOIS

1 · ZONA DE RISCO ATÉ OS 75'

Advertido em lance de risco → **substituir**

2 · ZAGUEIRO ADVERTIDO NO 1º TEMPO

5,3% são expulsos → **decidir no intervalo**

3 · PLANO PARA JOGAR COM 10

Sofridos +53% → **fechar a defesa**

≈ 0,9 PONTO

PERDIDO POR TIME, POR TEMPORADA, EM EXPULSÕES

POR QUE IMPORTA

Em **5 de 11** temporadas, o 16º e o 17º ficaram separados por até 1 ponto.



CADA EXPULSÃO EVITADA VALE 0,30 PONTO. E BOA PARTE DELAS É PREVISÍVEL.

DO CSV À RECOMENDAÇÃO: CINCO ETAPAS, CADA UMA COM ESCOLHAS

SELEÇÃO

8.785
partidas no arquivo

→ **4.179** em 2014–2024

→

PRÉ-PROCESSAMENTO

6
inconsistências tratadas

+ **1.198** posições ausentes

→

TRANSFORMAÇÃO

30.814
eventos em linha do tempo

→ **75.222** fotografias

→

MINERAÇÃO

3
métodos para o mesmo efeito

684 expulsões pareadas

→

AVALIAÇÃO

2022–24
teste nunca visto no treino

7 modelos comparados

Em cada etapa: o que encontramos, o que decidimos e quanto afetou.

CINCO HIPÓTESES, UMA PERGUNTA DA COMISSÃO EM CADA

	HIPÓTESE	PARA O CLUBE	MÉTODO	RESPOSTA	SLIDE
H1	**O vermelho reduz os pontos do punido, com placar, mando e força controlados**	Quanto custa uma expulsão?	estado + pareamento	SUSTENTADA	H1·H2
H2	**Expulsão mais cedo custa mais**	Quando ela pesa mais?	estado + pareamento	EM PARTE	H1·H2
H3	**Quem está perdendo leva mais vermelhos (causalidade reversa)**	O placar precisa entrar no controle?	taxa por exposição	SUSTENTADA	H3
H4	**O efeito difere entre mandante e visitante**	Fora de casa é pior?	estado + pareamento	SEM CONCLUSÃO	H4·gols
H5	**Vermelhos se concentram em posições e nos minutos finais**	Quem e quando orientar?	taxa por exposição	SUSTENTADA	H5·a · H5·b

H5: sustentada para o minuto; para a posição, em parte (zagueiro acima, goleiro abaixo do esperado).

QUATRO ARQUIVOS PÚBLICOS, LIGADOS PELA PARTIDA

ARQUIVO	LINHAS	COLUNAS	UMA LINHA É...
`full`	8.785	16	partida
`estatisticas`	17.570	13	time × partida
`gols`	9.861	6	gol, com minuto
`cartoes`	20.953	8	cartão, com minuto e posição

Fonte: Adão Duque, *Brasileirao_Dataset* (GitHub/Kaggle), Série A 2003–2024.

19.867
AMARELOS

1.086
VERMELHOS

22
TEMPORADAS NO ARQUIVO

49,6%
VITÓRIAS DO MANDANTE

O ALVO DA ANÁLISE

Resultado final e **pontos** de cada time.

NEM TUDO O QUE ESTÁ NA BASE DEVE ENTRAR NA ANÁLISE

DADO	DECISÃO	POR QUÊ
Partidas de 2014 a 2024	**entram** (4.179)	Só a partir de 2014 há o minuto dos eventos.
Partidas de 2003 a 2013	**só calibram o Elo**	Calibrar fora da janela de análise.
Estatísticas (chutes, posse…)	**ficam de fora**	Vazias antes de 2015 e em 2024, e são do jogo inteiro: vazamento.
Formação tática	**só no H5**	Referência de jogadores por posição.
Técnico e arena	**sem uso**	Nenhuma hipótese depende deles.

SEIS PROBLEMAS QUE A BASE NÃO AVISA

PROBLEMA	EXEMPLO	O QUE FIZEMOS	AFETADOS
Zero que era ausência	chutes = passes = faltas = 0	vira nulo	10.750
Mesmo estádio, vários nomes	Baixada · Kyocera · Ligga Arena	dicionário manual	? ⟶ ?
Vencedor contradiz o placar	partida 1114: “empate” com 0 × 1	vale o placar	1 JOGO
Grafia de posição	`Zagueira`	unificada em `Zagueiro`	22
Temporada ≠ ano	2020 acabou em fev/2021	data de corte	380 JOGOS
Rodada incompleta	2016 tem 379 jogos	mantida, com aviso	1 JOGO

Cada correção é uma regra no código: os arquivos brutos nunca são editados.

1.198 CARTÕES CHEGARAM SEM POSIÇÃO

1.198
CARTÕES SEM POSIÇÃO

→

−795
HERDAM A POSIÇÃO DO ATLETA

→

−32
ANOTADOS PELA ESCALAÇÃO

→

371
RESTANTES · 0 VERMELHOS

- **Regra:** a posição do atleta em ≥ 80% dos seus cartões.
- **À mão:** 28 vermelhos conferidos na escalação.

POR QUE NÃO DESCARTAR?

Enviesaria o H5 para 2019–2024.

CADA PARTIDA VIRA UMA SEQUÊNCIA DE SITUAÇÕES DE JOGO

Santos 3 × 1 Atlético-MG (09/09/2020), evento a evento.



Branco: 11 × 11. Vermelho: Atlético-MG com 10.

TRECHO

Placar e jogadores constantes: 15.126 no total.

EXPOSIÇÃO

Minutos perdendo, empatando ou vencendo: o denominador das taxas.

ACRÉSCIMO NÃO REGISTRADO

Duração **estimada**: o gol dos 90+9′ fecha a partida.

QUATRO INFORMAÇÕES QUE A BASE NÃO TINHA

TIPO DE VERMELHO

Amarelo antes, no mesmo jogo → 2º amarelo.

556 DIRETOS **529 POR 2º AMARELO** 1 sem atleta

MINUTO COM ACRÉSCIMO

`45+3` → tempo, minuto e acréscimo, ordenado antes de `46`.

FOTOGRAFIAS DO JOGO (LANDMARKS)

Placar e vermelhos a cada 5 minutos.

75.222 LINHAS · 18 por partida

FORÇA DOS TIMES (ELO)

Só com jogos **anteriores**, calibrado em 2004–2013.

OITO CHECAGENS RODAM A CADA EXECUÇÃO, E PARAM TUDO SE FALHAREM

gols por lado == placar final	✓
placar refeito evento a evento == placar final	✓
todo evento tem partida_id existente	✓
estatísticas: 2 linhas por partida	✓
jogadores em campo entre 7 e 11	✓
nenhum atleta com 2 vermelhos no jogo	✓
exposição de cada time == duração do jogo	✓
Elo: mudar um resultado não muda o passado	✓

POR QUE IMPORTA

Um gol no minuto errado muda o placar no momento do vermelho.

RESULTADO

Gols = placar em **100%** das partidas.

TRÊS FORMAS DE MEDIR O MESMO EFEITO

1 · TAXA POR EXPOSIÇÃO

Poisson por minuto exposto → **razão de taxas**.

H3, H5, gols

2 · MODELO DE ESTADO

Multinomial V/E/D em cada fotografia → **pontos esperados**.

H1, H2, H4

3 · PAREAMENTO

684 expulsos × até 5 pares no mesmo minuto, mando e saldo.

H1, H2, H4

DECISÕES NO CAMINHO

- Ordinal → **multinomial** (AIC 1.516 pontos melhor).
- Nenhum corte usa o futuro: só o **1º vermelho até os 90′**.

TREINAR NO PASSADO, TESTAR NO FUTURO



Treino 54.702 · teste 20.520 fotografias

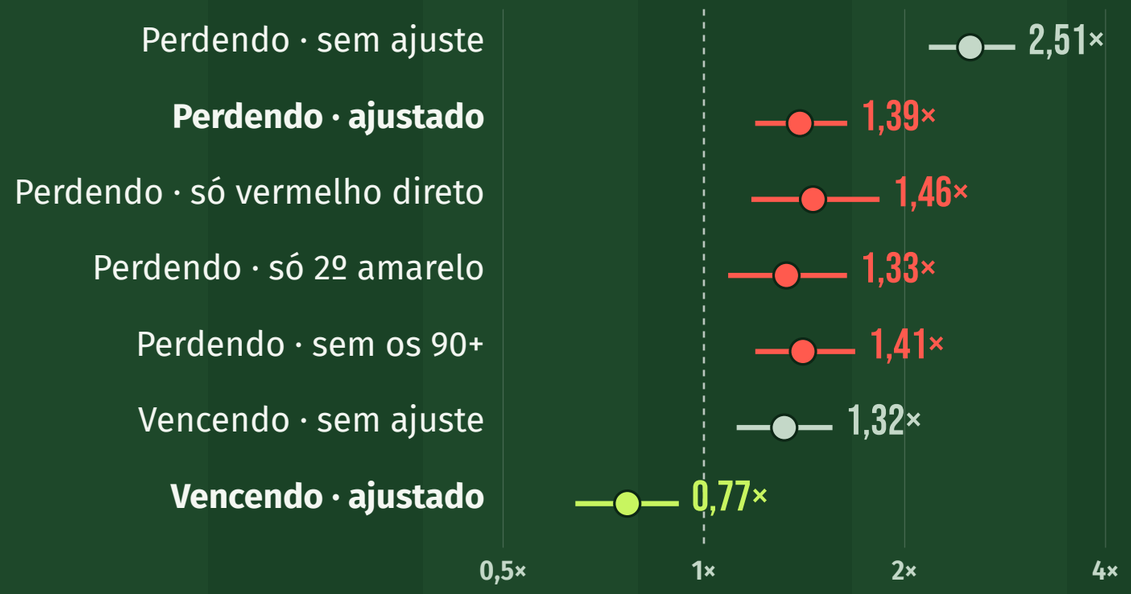
MODELO (TESTE)	LOG-LOSS	RPS	AUC	ACURÁCIA
sempre mandante	—	—	—	0,461
frequências históricas	1,066	0,224	0,500	0,461
Elo pré-jogo	1,035	0,213	0,610	0,476
logística ordinal	0,838	0,157	0,773	0,607
logística multinomial	0,828	0,156	0,781	0,614
random forest	0,831	0,156	0,777	0,610
LightGBM	0,853	0,159	0,764	0,599

- **Log-loss e RPS**: avaliam a probabilidade.
- CV **agrupada por partida**.

ESCOLHA

Multinomial: empata com a random forest e é interpretável.

QUEM ESTÁ PERDENDO LEVA 39% MAIS VERMELHOS, NO MESMO MINUTO



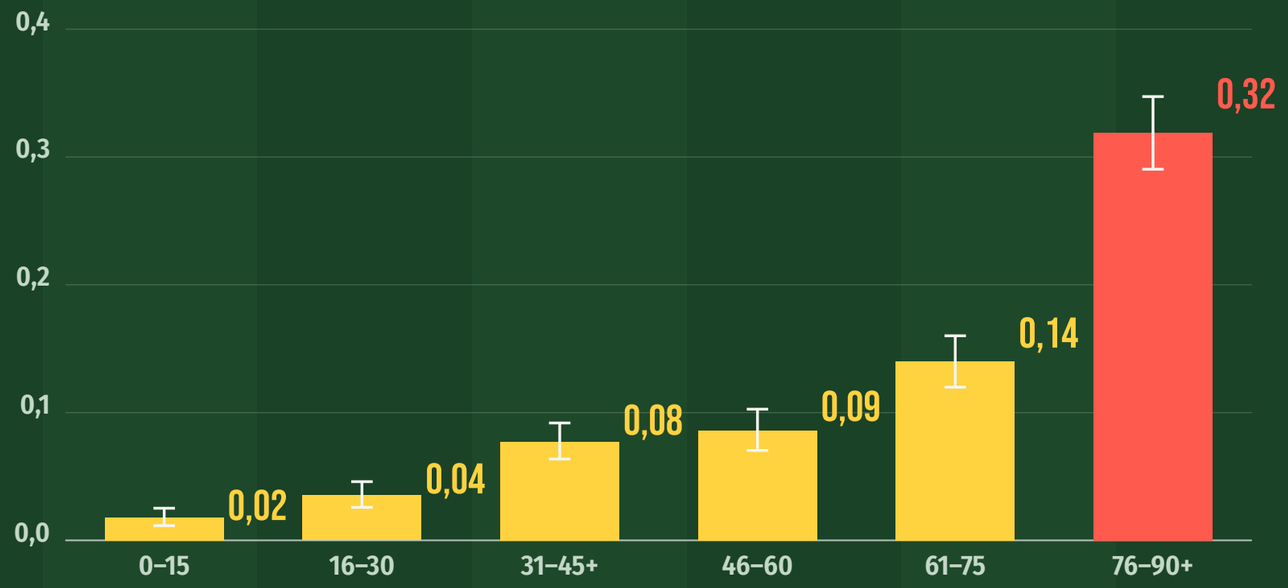
Razão de taxas contra **empatando**, IC 95%.

- Sem ajuste: ×2,51. Boa parte era **o minuto**.
- Ajustado: +39%, em todas as versões.

CONSEQUÊNCIA

O placar **precisa** entrar como controle no custo do vermelho.

O RISCO DE EXPULSÃO CRESCE A CADA 15 MINUTOS



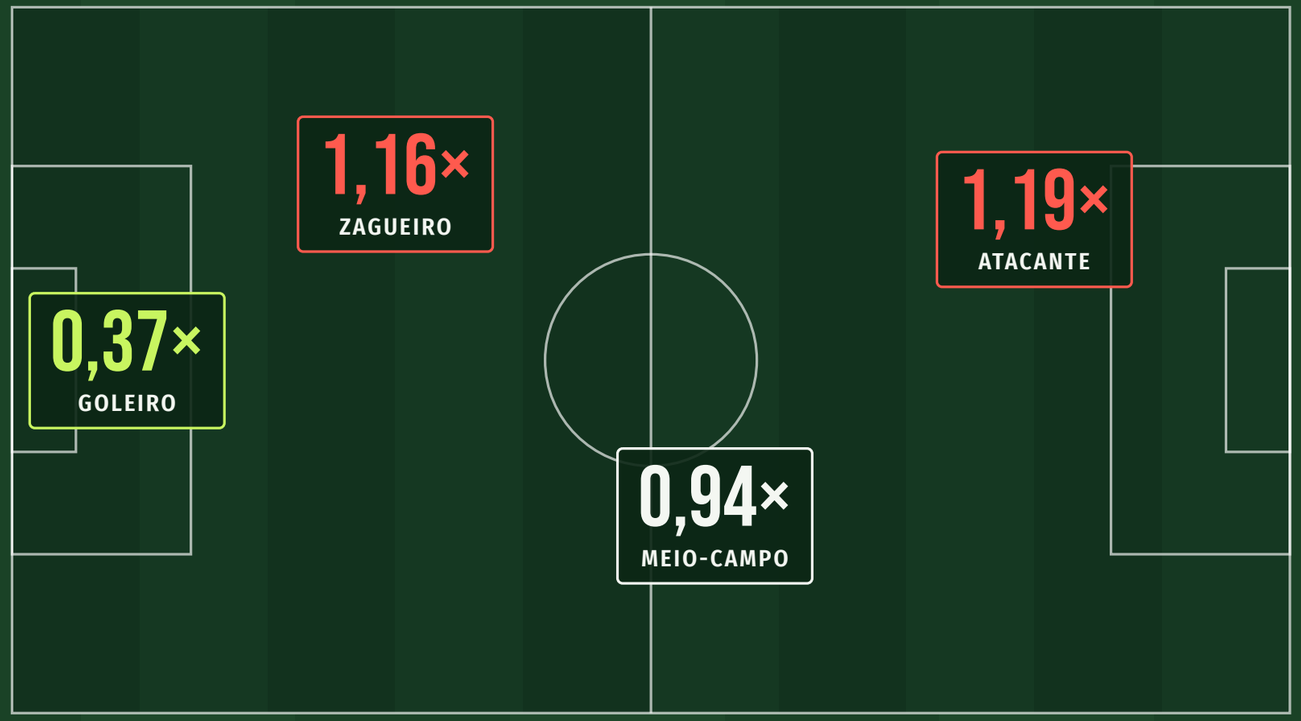
Vermelhos por time a cada 90 minutos, IC 95%.

18×

76–90+ CONTRA 0–15

- Vale para direto, 2º amarelo e todas as posições.

ZAGUEIRO LEVA 16% MAIS VERMELHOS DO QUE O ESPERADO



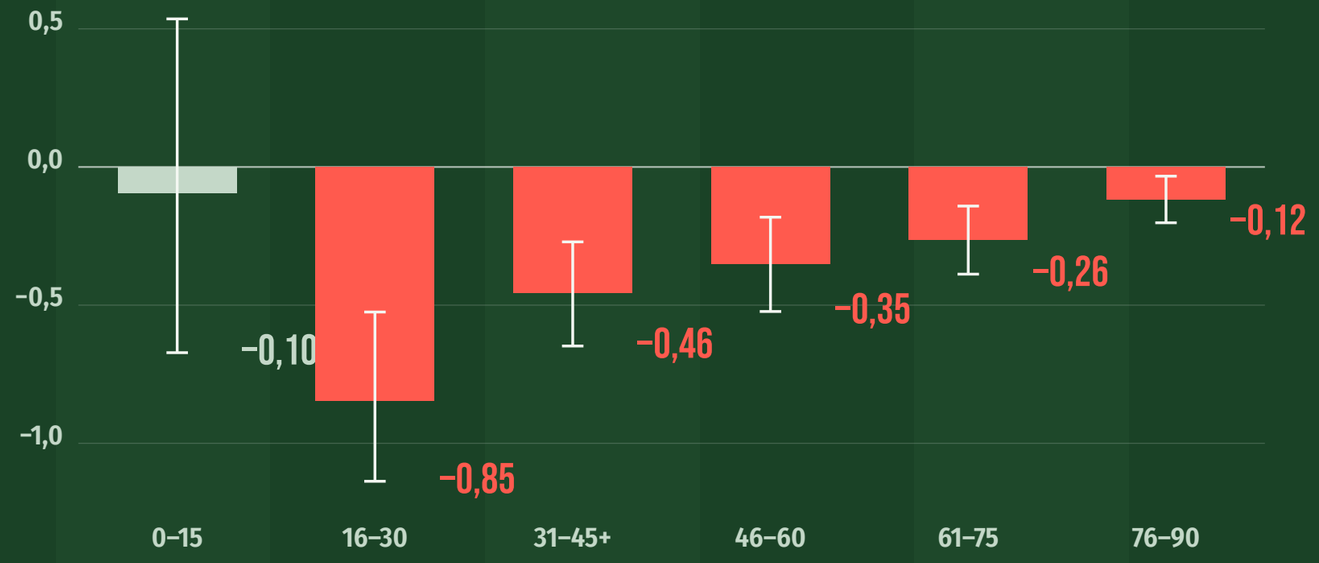
Observados ÷ esperados. Vermelho: acima · verde: abaixo · branco: inconclusivo (IC 95%).

- **Esperado:** jogadores da posição na formação.
- Zagueiros: 418 vermelhos contra 359.
- O goleiro do Atlético-MG é o caso raro.

PARA A COMISSÃO TÉCNICA

A orientação disciplinar começa pela **linha defensiva**.

UM VERMELHO CUSTA 0,30 PONTO, E CUSTA MAIS CEDO



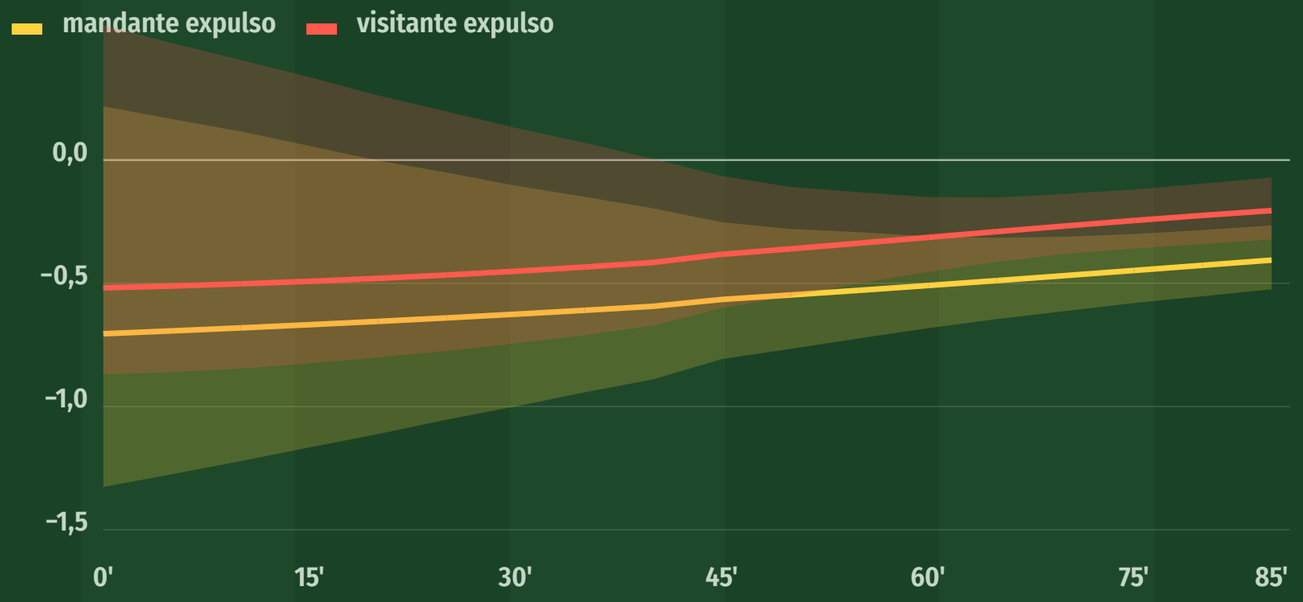
Pontos do expulso − pontos dos pares (ATT), pelo minuto do vermelho. Cinza: inclui zero.

−0,30

PONTO · IC −0,36 A −0,24

- **H1:** sustentada nos três métodos.
- **H2:** em parte, a queda não é significativa no modelo de estado.

O MODELO DE ESTADO CONFIRMA O TAMANHO DO CUSTO



Pontos esperados perdidos, jogo empatado (IC 95%).

−0,47

VERMELHO NO INTERVALO, EMPATADO

- Curva **instável** no início: a decisão usa o **pareamento**.

COM UM A MENOS, O PROBLEMA É DEFENDER

+53%

GOLS SOFRIDOS · IC 1,39 A 1,67×

−37%

GOLS MARCADOS · IC 0,54 A 0,72×

LEITURA TÁTICA

Perde-se mais pelo que se **sofre**: fechar a defesa.

H4 · MANDANTE × VISITANTE: SEM CONCLUSÃO FIRME

Mandante −0,40 × visitante −0,23, mas parte é **efeito teto**, e o modelo de estado não confirma.

O QUE ESTES DADOS NÃO PERMITEM AFIRMAR

ASSOCIAÇÃO, NÃO CAUSA

Dados observacionais: controles reduzem o viés, não o eliminam.

ACRÉSCIMO ESTIMADO

Duração é limite inferior: 152 vermelhos com tempo restante zero.

POSIÇÃO SEM ESCALAÇÃO

Sem volante; meio × ataque depende dos pontas.

POUCOS VERMELHOS CEDO

Só 25 nos 15 primeiros minutos.

PREVENIR ATÉ OS 75′, QUANDO A EXPULSÃO CUSTA CARO

PERCEBEMOS QUE	uma expulsão até os 75′ custa **0,39 ponto**, 3,2× a de depois dos 75′, e 50% dos vermelhos vêm do **2º amarelo**
ISSO SUGERE QUE	o atleta **já advertido** é o risco evitável, e o relógio diz quanto ele vale
RECOMENDAMOS	**zona de risco** até os 75′: advertido em lance de risco é candidato prioritário à substituição
SUSTENTADO POR	ATT pareado: até 75′ −0,39 (IC 95%: −0,47 a −0,30) · depois −0,12 (IC 95%: −0,21 a −0,04)
APÓS 1 TEMPORADA	avaliar por **vermelhos por 2º amarelo até os 75′** (liga: 1,1) · acompanhar por **pontos perdidos estimados** (liga: 0,9)
SUCESSO SE	**nenhuma** expulsão por 2º amarelo até os 75′ (quartil inferior da liga)

Um time médio da liga cumpre esta meta por acaso em 33% dos períodos: a meta é exigente, mas um único período não basta para provar efeito.

O ZAGUEIRO ADVERTIDO NO 1º TEMPO É O CASO DE MAIOR RISCO

PERCEBEMOS QUE	zagueiro advertido no 1º tempo é expulso em **5,3%** dos casos, contra 2,7% nas demais posições; no 2º tempo não há diferença. Zagueiros levam 16% mais vermelhos do que a formação explica
ISSO SUGERE QUE	o risco é o zagueiro com amarelo **e o 2º tempo inteiro** pela frente
RECOMENDAMOS	no **intervalo**, avaliar substituição ou mudança de função do zagueiro advertido; treino de bote e cobertura com a linha defensiva
SUSTENTADO POR	teste z de proporções: razão 1,98 (p de Holm < 0,001; no 2º tempo, p = 0,437) · H5: 1,16× o esperado
APÓS 1 TEMPORADA	avaliar por **vermelhos de zagueiros** (liga: mediana 2) · acompanhar por **expulsões de zagueiros advertidos no 1º tempo** (liga: 5,3% de ≈ 12 casos)
SUCESSO SE	no máximo **1** vermelho de zagueiro na temporada (quartil inferior da liga)

Um time médio da liga cumpre esta meta por acaso em 38% dos períodos: a meta é exigente, mas um único período não basta para provar efeito.

COM 10, O PLANO É NÃO SOFRER

PERCEBEMOS QUE	com um a menos, o time **sofre +53%** gols e **marca −37%**
ISSO SUGERE QUE	os pontos se perdem atrás: com 10, a prioridade é **não sofrer**
RECOMENDAMOS	**plano pré-treinado** para jogar com 10: preservar a linha defensiva, abrir mão de um atacante, acionar logo após a expulsão
SUSTENTADO POR	Poisson por minuto exposto: sofridos 1,53 (IC 95%: 1,39–1,67) · marcados 0,63 (IC 95%: 0,54–0,72)
APÓS 2 TEMPORADAS	avaliar por **gols sofridos por 90′ com um a menos** (liga: 1,87 com 10, 1,08 com 11) · acompanhar por **gols marcados com um a menos**
SUCESSO SE	no máximo **1,48** gol sofrido por 90′ com 10: metade do caminho até a taxa com 11

Duas temporadas porque um time passa só ≈ 90 minutos por ano com um a menos. Um time médio da liga cumpre esta meta por acaso em 28% dos períodos: a meta é exigente, mas um único período não basta para provar efeito.

FONTES E CÓDIGO

DADOS	Duque, A. *Campeonato Brasileiro de Futebol* (Brasileirao_Dataset). GitHub/Kaggle. `github.com/adaoduque/Brasileirao_Dataset`
LITERATURA	Caliendo, M.; Radic, D. *Ten Do It Better, Do They? An Empirical Analysis of an Old Football Myth*. IZA DP 2158, 2006.
CÓDIGO	`python -m src.run_all` · todos os números lidos de `reports/tabelas/`

OBRIGADO!

José Felix · Rafael Anacleto