Quanto custa uma expulsão?

Efeito do cartão vermelho, por minuto e contexto de jogo, no resultado das partidas do Campeonato Brasileiro Série A (2014–2024)

Relatório de andamento
José Felix · Ciência de Dados · UFAL/IC · 2026.1

Sumário

1. Aplicação 1
2. Base de Dados 2
   2.1. Origem e estrutura 2
   2.2. Pré-processamento 2
   2.3. Atributos derivados 3
   2.4. Validações 3
3. Estatística Descritiva e Inferência 4
   3.1. H3: placar no momento do vermelho 4
   3.2. H5: minuto e posição 4
4. Efeito do Vermelho no Resultado 6
   4.1. Métodos avaliados 6
   4.2. H1: o custo da expulsão 6
   4.3. H2: o custo depende do minuto? 6
   4.4. H4: mandante × visitante 7
   4.5. Gols após a expulsão 7
   4.6. Comparação de modelos e avaliação 8
5. Estado atual e próximos passos 9
Bibliografia 9

1. Aplicação

Problema. Qual o impacto de um cartão vermelho sobre o resultado de uma partida (pontos esperados, probabilidades de vitória, empate e derrota, e taxa de gols), e como esse impacto varia com o minuto da expulsão, o placar no momento, o mando de campo e a força relativa dos times.

Justificativa. A literatura sobre o Brasileirão se concentra em vantagem de mando e em previsão de resultados. O efeito do vermelho foi estudado com dados de Copas do Mundo [1], em que o efeito depende do minuto. Antes de afirmar que há lacuna para o Brasileirão, falta uma busca sistemática por "red card" e "Brazilian" com tempo ou minuto da expulsão.

Cliente e decisões apoiadas. A comissão técnica e o departamento de análise de desempenho de um clube da Série A. A análise deve apoiar:

- o protocolo disciplinar por posição e por fase do jogo;
- a conduta tática após uma expulsão, própria ou do adversário, conforme minuto e placar;
- a priorização de treinamento e de orientação aos atletas de maior risco disciplinar.

Hipóteses.

- **H1:** o vermelho reduz os pontos esperados do time punido, controlando placar no momento, mando e força relativa.
- **H2:** o efeito depende do minuto, com expulsões mais cedo custando mais.

Arquivo	Linhas	Colunas	Granularidade
`full`	8.785	16	partida
`estatisticas-full`	17.570	13	time por partida
`gols`	9.861	6	gol
`cartoes`	20.953	8	cartão

Tabela 1: Arquivos da base bruta. Fonte: `reports/tabelas/resumo_base.csv`.

- **H3:** existe causalidade reversa, pois times que estão perdendo recebem mais vermelhos. Sem controlar o placar no momento, o efeito fica superestimado.
- **H4:** o efeito difere entre mandante e visitante.
- **H5:** os vermelhos se concentram em posições específicas e nos minutos finais.
- **H6 (contexto):** a vantagem de mando diminuiu entre 2003 e 2024, ou em 2020, nos jogos sem público.

2. Base de Dados

2.1. Origem e estrutura

Os dados vêm do conjunto "Campeonato Brasileiro de Futebol", de Adão Duque, disponível em https://github.com/adaoduque/Brasileirao_Dataset e no Kaggle. São quatro arquivos CSV ligados por `ID` (partida) ou `partida_id`.

O arquivo de partidas cobre 22 temporadas, de 2003 a 2024. O minuto de gols e cartões existe de 2014 a 2024, que correspondem a 4.179 partidas, o período da análise. Nesse período há 19.867 cartões amarelos e 1.086 vermelhos, em 876 partidas (21,0% delas). Em todo o histórico, o mandante vence 49,6% das partidas e empata 26,4%.

Dos 1.086 vermelhos, 162 ocorreram até o minuto 45 do 1º tempo e 38 no acréscimo do 1º tempo. Poucas expulsões precoces limitam a precisão das estimativas para esse grupo.

2.2. Pré-processamento

O script `src/clean.py` lê `data/raw/`, que nunca é alterado, e grava tabelas limpas em `data/interim/` no formato parquet. O download e a conferência de linhas e colunas ficam em `src/download.py`. O pipeline completo, do download às figuras e a este documento, roda com `python -m src.run_all`.

Minutos com acréscimo. Valores como `45+2` são separados em `tempo`, `minuto_base`, `acrescimo`, `minuto_jogado` (base mais acréscimo) e `ordem` (base mais acréscimo dividido por 100). A chave `ordem` garante que `45+3` venha antes de `46`.

Temporada. A coluna `temporada` usa o ano da data, com uma exceção: os jogos de 2021 anteriores a 1º de março de 2021 pertencem à temporada 2020, que terminou em 25/02/2021. A regra funciona porque as temporadas de 2020 e 2021 não se sobrepõem, e cada uma fica com 380 jogos.

Validação do número de jogos. De 2006 a 2024 cada temporada deve ter 380 jogos. A temporada 2016 tem 379, pois a rodada 38 tem 9 jogos, e isso gera um aviso em vez de erro. As temporadas de 2003 a 2005 têm formato diferente (24 times) e ficam fora dessa regra.

Resultado da partida. `resultado_mandante` (V, E ou D) é derivado do placar. A coluna `vencedor` diverge do placar em uma partida de 2005 (`partida_id` 1114), registrada como empate com placar de 0 a 1, e essa divergência é avisada na execução. Foi escolhido o placar por ser validado contra os gols.

Estatísticas ausentes. Linhas com chutes, passes e faltas todos iguais a zero são ausências disfarçadas, e viram valores nulos em todas as colunas de estatística, preservando os cartões. Foram 10.750 linhas,

das quais 50 dentro de 2015–2023, o período em que as estatísticas deveriam ser válidas. Posse de bola e precisão de passes, que vinham como texto (`"55%"`), foram convertidas para número.

Posição nos cartões. A variante `Zagueira` (22 linhas, todas do mesmo atleta) foi unificada em `Zagueiro`. Havia 1.198 cartões sem posição, todos de 2014 a 2018. O preenchimento segue duas etapas, registradas na coluna `posicao_origem`:

1. **Imputação automática:** usa a posição do mesmo atleta em outros cartões, se ele tiver uma só posição, ou se a mais frequente cobrir pelo menos 80% dos seus registros. Foram imputadas 795 linhas. A posição na base parece ser a da partida e não fixa por atleta, e por isso o limiar de 80%.
2. **Levantamento manual:** os 28 vermelhos sem posição segura foram consultados na escalação de cada jogo e registrados em `data/manual/posicao_vermelhos.csv`. Laterais foram registrados como `Zagueiro`, seguindo a convenção da base. Posições manuais prevalecem sobre as imputadas. Foram preenchidas 32 linhas, número maior que 28 porque a junção por partida e atleta também alcança o amarelo anterior do mesmo jogador. Nas linhas que já tinham posição imputada, a anotação manual coincidiu com a imputação.

Restam 371 cartões sem posição, todos amarelos: os 1.086 vermelhos têm posição (0 nulos).

2.3. Atributos derivados

O script `src/features.py` grava as tabelas analíticas em `data/processed/`. Os números desta subseção vêm de `reports/tabelas/features_resumo.csv` e `elo_parametros.csv`.

Linha do tempo de eventos. Gols e cartões formam uma linha do tempo única (30.814 eventos), ordenada por minuto e, no mesmo minuto, com o gol antes do cartão e o amarelo antes do vermelho. Cada evento guarda o placar e o número de jogadores de cada lado antes e depois dele. Há 170 partidas com dois ou mais vermelhos.

Tipo de vermelho. A base não distingue vermelho direto de segundo amarelo. Um vermelho é classificado como 2º amarelo quando o mesmo atleta, do mesmo clube, tem um amarelo anterior na mesma partida. São 556 diretos, 529 por 2º amarelo e 1 indeterminado, sem atleta registrado.

Duração e tempo restante. A base não registra o acréscimo dado pelo árbitro. O acréscimo de cada tempo é estimado como o maior entre o acréscimo observado nos eventos da partida e a mediana desse valor na temporada. A duração mediana estimada passa de 94,5 minutos em 2014 para 98,0 em 2024. Mesmo assim, 152 vermelhos ficam com tempo restante zero, porque ocorreram depois da mediana de acréscimo e sem eventos posteriores. A estimativa é um limite inferior da duração real.

Estados de jogo e exposição. A partida é dividida em 15.126 trechos com placar e número de jogadores constantes, dos quais 465 têm duração zero (eventos simultâneos ou no último minuto registrado). Cruzando os trechos com faixas de 15 minutos, obtém-se, para cada time, quantos minutos ele passou em cada estado e quantos vermelhos e gols ocorreram ali. Essa exposição é a base dos testes da Seção 3.

Força relativa (Elo). Um rating Elo é calculado desde 2003 usando apenas jogos anteriores a cada partida. Os parâmetros foram escolhidos por log-loss em 2004–2013, fora da janela de análise, e o resultado foi K = 12,0, vantagem de mando de 107,1 pontos e regressão de 38% à média entre temporadas, com multiplicador por saldo de gols. A log-loss na calibração foi 1,0211, contra 1,0369 do baseline de frequências históricas. Em 2014–2024 foi 1,0196. Um teste automático confirma que alterar o resultado de uma partida não muda o Elo pré-jogo dela nem o das anteriores.

2.4. Validações

- Os gols por lado, em `gols`, batem com o placar final em todas as partidas de 2014 a 2024. O placar reconstruído evento a evento também bate com o placar final.

- Todo evento de gol ou cartão tem `partida_id` presente em `partidas`, e `estatisticas` tem exatamente duas linhas por partida.
- O número de jogadores em campo fica entre 7 e 11, e nenhum atleta tem dois vermelhos na mesma partida.
- A exposição de cada time soma a duração estimada da partida, e as contagens de vermelhos e gols na tabela de exposição batem com os eventos.

Pendências de qualidade: padronização de nomes de arenas (168 valores distintos, ainda não verificados). A formação passou a ser usada no H5 (disponível de 2015 a 2024). O técnico continua sem uso.

3. Estatística Descritiva e Inferência

Os testes estão em `src/stats_tests.py`, e as tabelas em `reports/tabelas/h3_*.csv` e `h5_*.csv`.

Método comum. Comparar contagens brutas de vermelhos engana, porque os times passam tempos diferentes em cada situação. Por isso, a medida é a **taxa por 90 minutos de exposição**. Os efeitos ajustados vêm de uma regressão de Poisson com offset igual ao logaritmo da exposição, que estima a **razão de taxas** (IRR) entre situações. Os intervalos de confiança de 95% vêm de um bootstrap por partida com 2.000 réplicas. O p-valor usa o erro-padrão desse bootstrap, que leva em conta a dependência entre trechos do mesmo jogo. Dentro de cada família de testes (H3 e H5), os p-valores são corrigidos por Holm, e os valores citados abaixo já estão corrigidos.

3.1. H3: placar no momento do vermelho

Sem ajuste. O time que está perdendo recebe 0,210 vermelho por 90 minutos, contra 0,084 empatando e 0,110 vencendo. A distribuição dos vermelhos difere da distribuição da exposição (qui-quadrado, $p < 0{,}001$; V de Cramér = 0,30).

Ajustado. Parte dessa diferença vem do minuto, porque o tempo em que um time está perdendo se concentra no fim do jogo, que é quando os vermelhos se concentram. Controlando faixa de minuto, mando, quintil de diferença de Elo e vantagem numérica, a IRR de perdendo contra empatando cai de 2,51 para 1,39 (IC 95%: 1,19–1,64) ($p < 0{,}001$). A de vencendo inverte o sinal: de 1,32 sem ajuste para 0,77 (IC 95%: 0,64–0,92) ($p = 0{,}010$). Ou seja, o aparente risco maior de quem vence era efeito do minuto.

Por tipo de vermelho. O efeito de estar perdendo aparece tanto no vermelho direto, IRR 1,46 (IC 95%: 1,18–1,83), quanto no 2º amarelo, IRR 1,33 (IC 95%: 1,09–1,64).

Robustez. O resultado se mantém sem os vermelhos de 90+, com IRR 1,41 (IC 95%: 1,19–1,69), e só em 2015–2024, com IRR 1,36 (IC 95%: 1,15–1,61). Com o saldo em cinco níveis, o risco se concentra em **perder por um gol**, com IRR 1,48 (IC 95%: 1,26–1,75). Perder por dois ou mais dá 1,17 (IC 95%: 0,93–1,45), com intervalo que inclui 1.

Conclusão. A H3 é sustentada: times perdendo recebem mais vermelhos, mesmo comparando o mesmo minuto, mando e força. Para estimar o efeito do vermelho no resultado (H1 e H2), portanto, o placar no momento precisa entrar como controle. Caso contrário, o efeito fica superestimado.

3.2. H5: minuto e posição

Minuto. A taxa de vermelhos cresce ao longo do jogo, de 0,018 por 90 minutos na faixa 0–15 para 0,319 na faixa 76–90+ (qui-quadrado contra a exposição, $p < 0{,}001$; V de Cramér = 0,39). O padrão vale para vermelhos diretos e para 2º amarelo. O 2º amarelo é praticamente ausente nos primeiros 15 minutos, como esperado. A taxa nos acréscimos do 2º tempo, 0,73 por 90 minutos, está inflada pela subestimação da duração e não deve ser lida isoladamente. Um modelo de tendência linear por faixa se ajusta mal (dispersão de 6,1), porque o crescimento acelera no fim. Por isso, a evidência principal são as taxas por faixa.

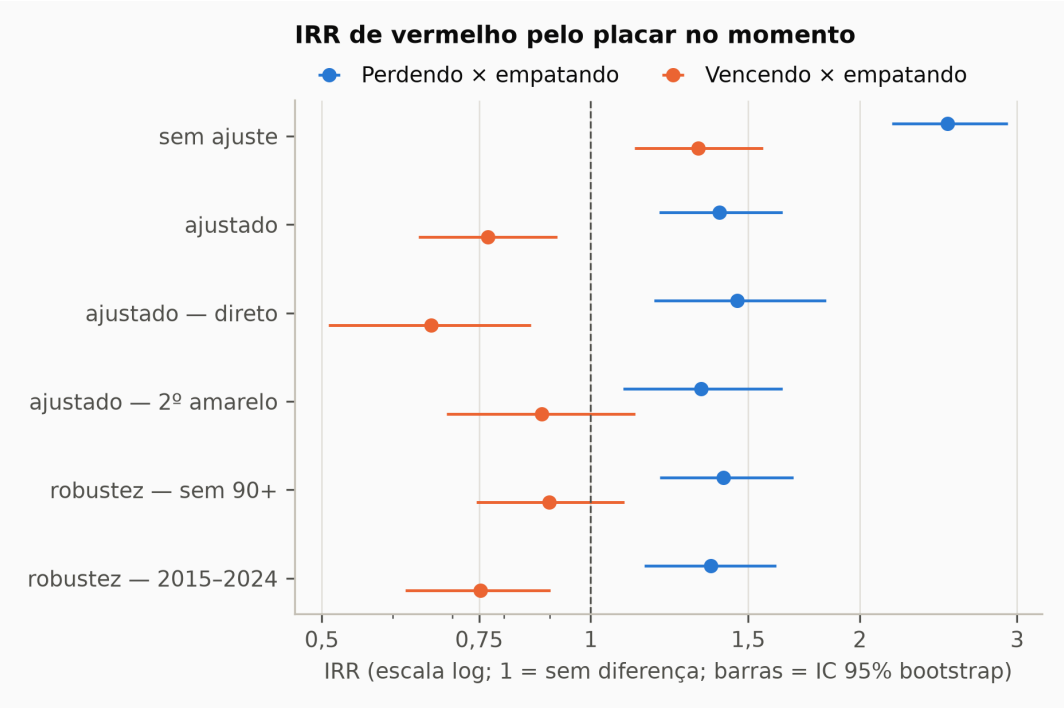


Figura 1: Razão de taxas de vermelho (IRR) de perdendo e de vencendo contra empatando, nos modelos principal e de robustez. Fonte: `reports/tabelas/h3_irr.csv`.

Posição em relação à formação. Sem escalação, a referência é a formação de cada jogo (de 2015 a 2024): numa 4-2-3-1, por exemplo, espera-se que 4 dos 11 jogadores sejam defensores. Os zagueiros (que na base incluem laterais) recebem 1,16 vez o esperado (IC 95%: 1,08–1,25), e os goleiros, 0,37 (IC 95%: 0,25–0,50). A distribuição difere da esperada ($p < 0{,}001$; V de Cramér = 0,13). O resultado de meio-campo e atacante, por outro lado, **depende de como os pontas são classificados**: o atacante fica acima do esperado na referência principal (1,19) e bem abaixo quando os pontas contam como ataque (0,46). Para essas duas posições, não há conclusão.

Gravidade entre os punidos. Entre os atletas que receberam algum cartão na partida, o zagueiro foi expulso em 6,2% dos casos (IC 95% de Wilson: 5,7–6,8%) e o meio-campo em 4,7% (4,3–5,2%). A diferença é significativa (p de Holm < 0,001), mas o efeito é pequeno (V de Cramér = 0,03).

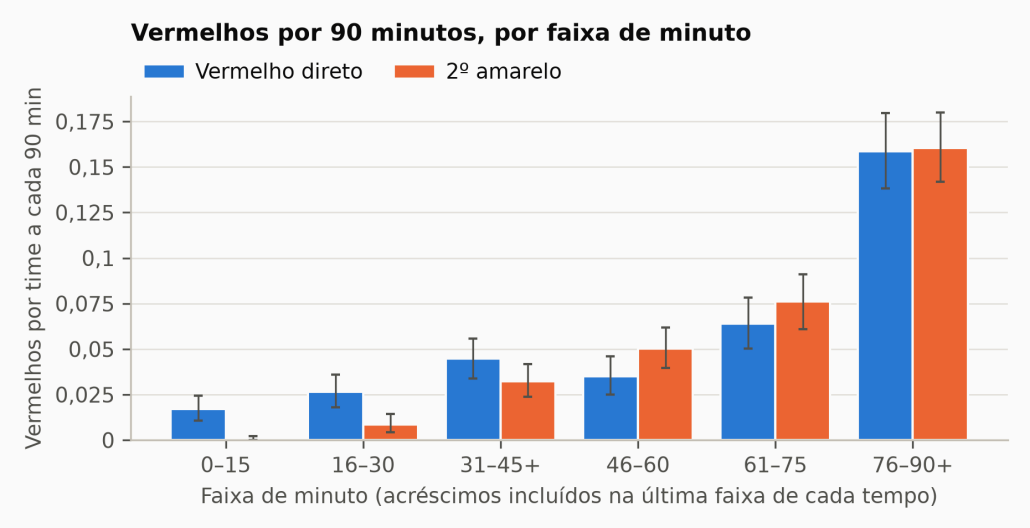


Figura 2: Vermelhos por time a cada 90 minutos, por faixa de minuto e tipo de vermelho, com IC 95% bootstrap. Fonte: `reports/tabelas/h5_taxas_faixa.csv`.

Posição × minuto. Não há associação entre posição e faixa de minuto do vermelho (p = 0,532; V de Cramér = 0,07). Todas as posições se concentram no fim do jogo da mesma forma. A tabela tem 5 de 24 células com esperado < 5, o que pede cautela com o goleiro.

Conclusão. A H5 é sustentada para o minuto e, em parte, para a posição: zagueiros acima e goleiros abaixo do esperado. Como posição e minuto não interagem, um protocolo disciplinar pode tratar os dois critérios separadamente. A base não distingue volantes dentro de meio-campo.

4. Efeito do Vermelho no Resultado

Os modelos estão em `src/models.py` e `src/evaluate.py`, e as tabelas em `reports/tabelas/h1_*.csv` e `modelos_*.csv`. A população do efeito são as partidas cujo primeiro vermelho ocorreu até o minuto 90 regulamentar. O corte usa o minuto do vermelho, que é conhecido no momento, e nunca o que aconteceu depois dele, o que criaria viés de seleção.

4.1. Métodos avaliados

Modelo de estado do jogo. Cada partida é fotografada em minutos fixos (0, 5, …, 85), os *landmarks*. Em cada um, o modelo estima a probabilidade de vitória, empate e derrota do mandante a partir do estado naquele momento: saldo (também escalado pela raiz do tempo restante), tempo restante, diferença de Elo e sua interação com o tempo restante, e o número de vermelhos de cada lado com e sem interação com o tempo restante. Partidas sem vermelho no mesmo estado servem de comparação, e o placar no momento fica controlado, como exige a H3. O **custo da expulsão** é a variação de pontos esperados do time punido, $\Delta PE = PE(\text{com o vermelho}) - PE(\text{sem})$, em que $PE = 3 \cdot P(\text{vitória}) + P(\text{empate})$. Os intervalos vêm de 2.000 simulações dos parâmetros com covariância robusta agrupada por partida.

Multinomial × ordinal. O plano previa a logística ordinal como principal. A suposição de chances proporcionais, porém, não se sustentou: o AIC da ordinal ficou 1.516 pontos acima do da multinomial, e no teste temporal a log-loss da ordinal foi maior em 0,0098 (IC 95%: 0,0061 a 0,0135). Por isso a **multinomial é o modelo principal**, e a ordinal fica como comparação.

Pareamento. Cada time expulso é comparado a 1–5 times de outras partidas que, no mesmo minuto, tinham o mesmo mando e o mesmo saldo (−2 a +2), ainda não tinham levado vermelho e tinham o Elo mais próximo. O controle pode levar vermelho depois, porque excluir esses casos seria usar o futuro. A medida é o ATT, a diferença média de pontos finais entre expulsos e controles, com IC bootstrap. O equilíbrio ficou bom: diferença padronizada de Elo de −0,002.

Gols. Uma regressão de Poisson sobre a tabela de exposição estima a taxa de gols marcados com um jogador a menos ou a mais, controlando faixa de minuto, saldo, mando e Elo. Como robustez, há um modelo com efeito fixo de partida, que compara o antes e o depois dentro do mesmo jogo.

4.2. H1: o custo da expulsão

O vermelho reduz os pontos do time punido nos três métodos. No modelo de estado, um vermelho no intervalo (minuto 45), com o jogo empatado, custa −0,47 (IC 95%: −0,65 a −0,26) ponto esperado (p de Holm < 0,001). No pareamento, com 684 expulsões, o ATT é de −0,30 (IC 95%: −0,36 a −0,24) ponto por partida (p de Holm < 0,001). Os expulsos fizeram em média 0,85 ponto, e seus controles, 1,15.

4.3. H2: o custo depende do minuto?

A resposta depende do método. No pareamento, o custo cai ao longo do jogo: de −0,85 (IC 95%: −1,14 a −0,52) ponto para expulsões entre os minutos 16 e 30, para −0,12 (IC 95%: −0,20 a −0,03) entre 76 e 90. No modelo multinomial, as interações com o tempo restante são significativas (Wald, p de Holm < 0,001). Com o jogo empatado, porém, a diferença de custo entre os minutos 15 e 75 é de −0,23 (IC 95%: −0,57 a 0,29), sem significância (p de Holm = 0,586). Na ordinal, a mesma diferença é −0,38 (p = 0,007, sem correção). Os primeiros 15 minutos têm só 25 expulsões, com IC de −0,67 a 0,54, e não permitem

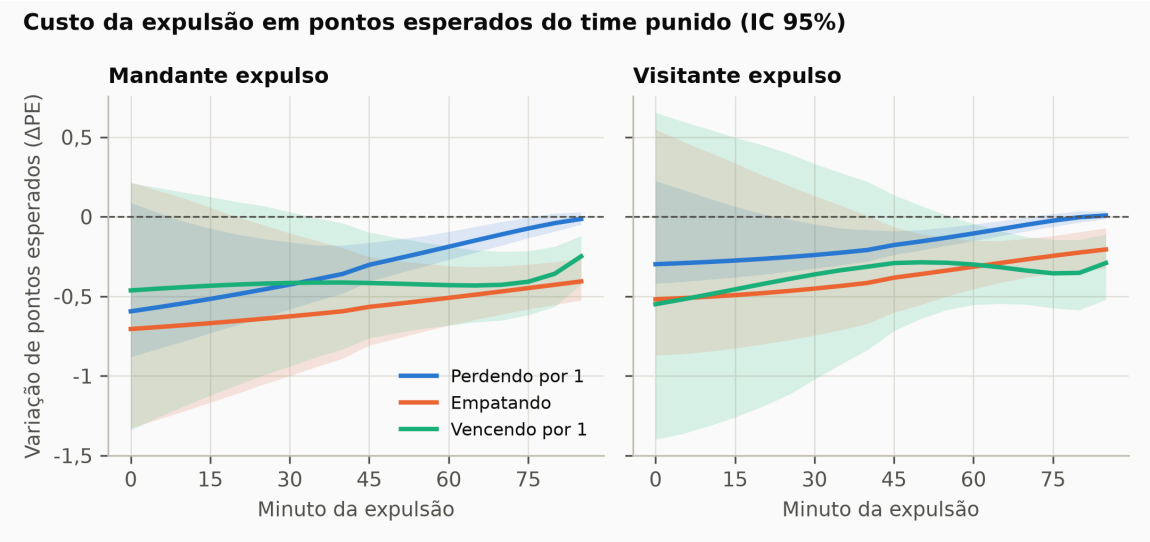


Figura 3: Custo da expulsão em pontos esperados do time punido, por minuto, placar no momento e lado punido (multinomial, IC 95%). As pontas iniciais das curvas de perdendo e vencendo são extrapolação, pois esses placares não ocorrem no início. Fonte: `reports/tabelas/h1_custo_minuto.csv`.

conclusão. A H2 é sustentada em parte: o custo existe em todo o jogo, mas a forma da queda ainda é incerta.

4.4. H4: mandante × visitante

No pareamento, o mandante expulso perde −0,40 (IC 95%: −0,51 a −0,29) ponto, e o visitante, −0,23 (IC 95%: −0,32 a −0,15). A diferença, −0,17, é significativa no limite (p de Holm = 0,049). Parte dela é efeito teto: os controles do mandante fizeram 1,52 ponto, e os do visitante, 0,90, então o mandante tem mais a perder. No modelo de estado, a diferença não é significativa (−0,18; p de Holm = 0,586). A H4 não tem conclusão firme.

4.5. Gols após a expulsão

Com um jogador a menos, o time marca gols a uma taxa 0,63 vez a da igualdade numérica (IC 95%: 0,54–0,72). Com um a mais, a taxa é 1,53 vez (IC 95%: 1,39–1,67). No modelo com efeito fixo de partida, os valores são 0,71 e 1,99. Ou seja, a expulsão pesa mais pelos gols sofridos a mais do que pelos gols marcados a menos.

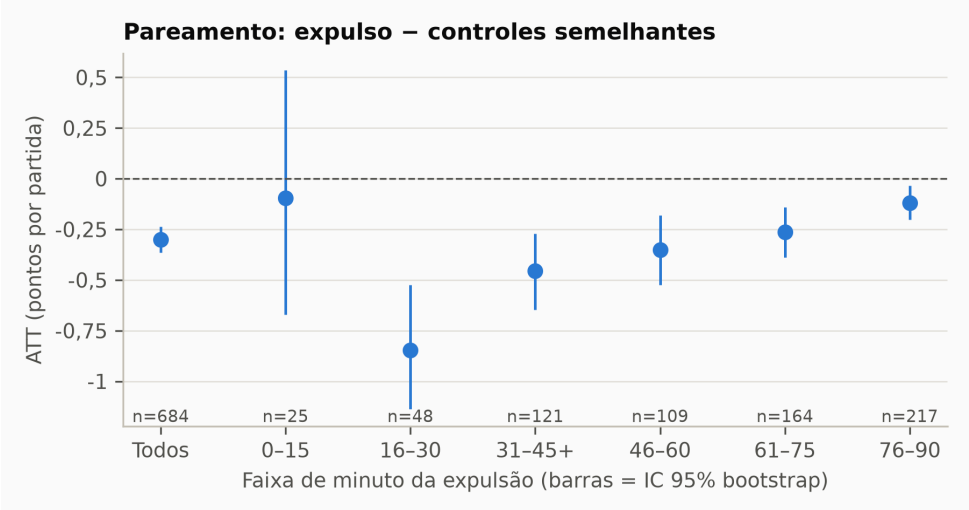


Figura 4: ATT do pareamento por faixa de minuto da expulsão, com IC 95% bootstrap. Fonte: `reports/tabelas/h1_pareamento_att.csv`.

Modelo	Log-loss	Brier	RPS	AUC	Acurácia	F1 macro
sempre mandante	—	—	—	—	0,461	0,210
frequências históricas	1,066	0,644	0,224	0,500	0,461	0,210
Elo pré-jogo	1,035	0,621	0,213	0,610	0,476	0,278
logística ordinal	0,838	0,495	0,157	0,773	0,607	0,557
logística multinomial	0,828	0,489	0,156	0,781	0,614	0,556
random forest	0,831	0,490	0,156	0,777	0,610	0,547
LightGBM	0,853	0,501	0,159	0,764	0,599	0,544

Tabela 2: Métricas no teste (2022–2024, todos os landmarks). "Sempre mandante" não produz probabilidades. Fonte: `reports/tabelas/modelos_metricas.csv`.

4.6. Comparação de modelos e avaliação

Todos os modelos preveem o resultado final a partir do estado em cada landmark. A validação é temporal: treino em 2014–2021 e teste em 2022–2024, simulando o uso real (treina-se com o passado e aplica-se ao futuro). Os hiperparâmetros da random forest e do LightGBM foram escolhidos por log-loss em validação cruzada de 5 grupos **por partida** dentro do treino, para que landmarks do mesmo jogo nunca fiquem nos dois lados. Os baselines obrigatórios são "sempre mandante" e as frequências históricas. A acurácia sozinha é inadequada por causa dos empates, e por isso as métricas principais são log-loss e RPS (*ranked probability score*), próprio para resultados ordenados.

A multinomial tem a menor log-loss no teste. A random forest fica próxima, com diferença de 0,0027 (IC 95%: −0,0047 a 0,0106), intervalo que inclui zero. O LightGBM fica atrás, com diferença de 0,0244 (IC 95%: 0,0116 a 0,0377). Como a multinomial é tão boa quanto o melhor modelo flexível e é interpretável, ela é o modelo de decisão. Entre os landmarks com vermelho, as árvores ficam levemente à frente (log-loss 0,6666 do LightGBM contra 0,6733 da multinomial).

Estabilidade da curva de custo. Ajustada só no treino, a multinomial estima −0,87 ponto para o visitante expulso no início com o jogo empatado. Com todos os dados, estima −0,52. Há poucos vermelhos para identificar bem esses coeficientes. Por isso, para a recomendação, a evidência mais robusta é o ATT do pareamento, e a curva do modelo serve para mostrar o formato do custo ao longo do jogo.

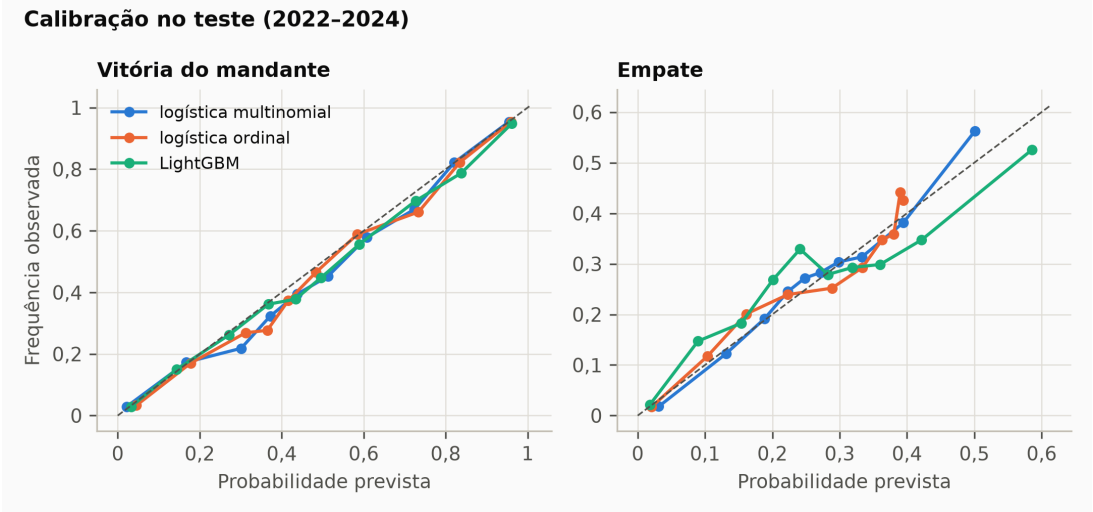


Figura 5: Curva de calibração no teste para vitória do mandante e empate. Fonte: `src/evaluate.py`.

5. Estado atual e próximos passos

Concluído: download, limpeza, anotação manual das posições, atributos derivados (eventos, estados, exposição, landmarks, Elo), testes de H3 e H5, modelos do efeito (H1, H2, H4) e comparação de modelos com validação temporal. Pendente: insights no formato exigido, com métricas de acompanhamento e critérios de sucesso; documento final no template SBC; dashboard com o custo da expulsão por minuto.

Bibliografia

[1] Marco Caliendo e Dubravko Radic. 2006. *Ten Do It Better, Do They? An Empirical Analysis of an Old Football Myth.*