Quanto custa uma expulsão?

Efeito do cartão vermelho, por minuto e contexto de jogo, no resultado das partidas do Campeonato Brasileiro Série A (2014–2024)

Relatório de andamento
José Felix · Ciência de Dados · UFAL/IC · 2026.1

Sumário

1. Aplicação 1
2. Base de Dados 1
   2.1. Origem e estrutura 1
   2.2. Pré-processamento 2
   2.3. Validações 3
3. Estado atual e próximos passos 3
Bibliografia 3

1. Aplicação

Problema. Qual o impacto de um cartão vermelho sobre o resultado de uma partida (pontos esperados, probabilidades de vitória, empate e derrota, e taxa de gols), e como esse impacto varia com o minuto da expulsão, o placar no momento, o mando de campo e a força relativa dos times.

Justificativa. A literatura sobre o Brasileirão se concentra em vantagem de mando e em previsão de resultados. O efeito do vermelho foi estudado com dados de Copas do Mundo [1], em que o efeito depende do minuto. Antes de afirmar que há lacuna para o Brasileirão, falta uma busca sistemática por "red card" e "Brazilian" com tempo ou minuto da expulsão.

Cliente e decisões apoiadas. A comissão técnica e o departamento de análise de desempenho de um clube da Série A. A análise deve apoiar:

- o protocolo disciplinar por posição e por fase do jogo;
- a conduta tática após uma expulsão, própria ou do adversário, conforme minuto e placar;
- a priorização de treinamento e de orientação aos atletas de maior risco disciplinar.

Hipóteses.

- **H1:** o vermelho reduz os pontos esperados do time punido, controlando placar no momento, mando e força relativa.
- **H2:** o efeito depende do minuto, com expulsões mais cedo custando mais.
- **H3:** existe causalidade reversa, pois times que estão perdendo recebem mais vermelhos. Sem controlar o placar no momento, o efeito fica superestimado.
- **H4:** o efeito difere entre mandante e visitante.
- **H5:** os vermelhos se concentram em posições específicas e nos minutos finais.
- **H6 (contexto):** a vantagem de mando diminuiu entre 2003 e 2024, ou em 2020, nos jogos sem público.

2. Base de Dados

2.1. Origem e estrutura

Os dados vêm do conjunto "Campeonato Brasileiro de Futebol", de Adão Duque, disponível em https://github.com/adaoduque/Brasileirao_Dataset e no Kaggle. São quatro arquivos CSV ligados por `ID` (partida) ou `partida_id`.

Arquivo	Linhas	Colunas	Granularidade
`full`	8.785	16	partida
`estatisticas-full`	17.570	13	time por partida
`gols`	9.861	6	gol
`cartoes`	20.953	8	cartão

Tabela 1: Arquivos da base bruta. Fonte: `reports/tabelas/resumo_base.csv`.

O arquivo de partidas cobre 22 temporadas, de 2003 a 2024. O minuto de gols e cartões existe de 2014 a 2024, que correspondem a 4.179 partidas, o período da análise. Nesse período há 19.867 cartões amarelos e 1.086 vermelhos, em 876 partidas (21,0% delas). Em todo o histórico, o mandante vence 49,6% das partidas e empata 26,4%.

Dos 1.086 vermelhos, 162 ocorreram até o minuto 45 do 1º tempo e 38 no acréscimo do 1º tempo. Poucas expulsões precoces limitam a precisão das estimativas para esse grupo.

2.2. Pré-processamento

O script `src/clean.py` lê `data/raw/`, que nunca é alterado, e grava tabelas limpas em `data/interim/` no formato parquet. O download e a conferência de linhas e colunas ficam em `src/download.py`.

Minutos com acréscimo. Valores como `45+2` são separados em `tempo`, `minuto_base`, `acrescimo`, `minuto_jogado` (base mais acréscimo) e `ordem` (base mais acréscimo dividido por 100). A chave `ordem` garante que `45+3` venha antes de `46`.

Temporada. A coluna `temporada` usa o ano da data, com uma exceção: os jogos de 2021 anteriores a 1º de março de 2021 pertencem à temporada 2020, que terminou em 25/02/2021. A regra funciona porque as temporadas de 2020 e 2021 não se sobrepõem, e cada uma fica com 380 jogos.

Validação do número de jogos. De 2006 a 2024 cada temporada deve ter 380 jogos. A temporada 2016 tem 379, pois a rodada 38 tem 9 jogos, e isso gera um aviso em vez de erro. As temporadas de 2003 a 2005 têm formato diferente (24 times) e ficam fora dessa regra.

Resultado da partida. `resultado_mandante` (V, E ou D) é derivado do placar. A coluna `vencedor` diverge do placar em uma partida de 2005 (`partida_id` 1114), registrada como empate com placar de 0 a 1, e essa divergência é avisada na execução. Foi escolhido o placar por ser validado contra os gols.

Estatísticas ausentes. Linhas com chutes, passes e faltas todos iguais a zero são ausências disfarçadas, e viram valores nulos em todas as colunas de estatística, preservando os cartões. Foram 10.750 linhas, das quais 50 dentro de 2015–2023, o período em que as estatísticas deveriam ser válidas. Posse de bola e precisão de passes, que vinham como texto (`"55%"`), foram convertidas para número.

Posição nos cartões. A variante `Zagueira` (22 linhas, todas do mesmo atleta) foi unificada em `Zagueiro`. Havia 1.198 cartões sem posição, todos de 2014 a 2018. O preenchimento segue duas etapas, registradas na coluna `posicao_origem`:

1. **Imputação automática:** usa a posição do mesmo atleta em outros cartões, se ele tiver uma só posição, ou se a mais frequente cobrir pelo menos 80% dos seus registros. Foram imputadas 808 linhas. A posição na base parece ser a da partida e não fixa por atleta, e por isso o limiar de 80%.
2. **Levantamento manual:** 28 vermelhos sem posição segura foram listados em `data/manual/posicao_vermelhos.csv` para consulta à escalação do jogo. Posições manuais prevalecem sobre as imputadas. Até aqui, 0 foram preenchidas.

Restam 390 cartões sem posição, dos quais 17 vermelhos. A análise por posição (H5) deve reportar essa categoria à parte e testar a sensibilidade com e sem as posições imputadas.

2.3. Validações

- Os gols por lado, em `gols`, batem com o placar final em todas as partidas de 2014 a 2024.
- Todo evento de gol ou cartão tem `partida_id` presente em `partidas`.
- `estatisticas` tem exatamente duas linhas por partida.

Pendências de qualidade: padronização de nomes de arenas (168 valores distintos, ainda não verificados) e escolha de uso para técnico e formação, que têm cerca de 53–57% de nulos.

3. Estado atual e próximos passos

Concluído: `download.py`, `clean.py` e `resumo_base.py` (que gera os números deste relatório). Pendente: preenchimento manual de posições, `features.py` (eventos, placar no momento, Elo), estatística descritiva e testes de hipótese, modelos do efeito, avaliação e insights. As seções de métodos, métricas, resultados e conclusão do documento final serão escritas quando houver resultados.

Bibliografia

[1] Marco Caliendo e Dubravko Radic. 2006. *Ten Do It Better, Do They? An Empirical Analysis of an Old Football Myth.*